THỰC HÀNH 1: MÁY HỌC CƠ BẢN PHẦN 1

Mục tiêu: Thao tác cơ bản với python. Hiểu được cách sử dụng python để hiện thực một số thuật toán máy học cơ bản.

1. Các kiểu dữ liệu có cấu trúc trong python

Array là một cấu trúc đặc biệt dùng để biểu diễn cho 1 vector. Python cung cấp thư viện numpy để xử lý đối với dữ liệu dạng vector. Để sử dụng numpy, ta phải import vào bằng lệnh:

```
import numpy as np
```

Chiều của các vector có thể khác nhau:

+ 1-D: `arr = np.array([1, 2, 3, 4, 5])`

+ 2-D: `arr = np.array([[1, 2, 3], [4, 5, 6]])`

+ 3-D: `arr = np.array([[[1, 2], [4, 5]], [[1, 3], [5, 6]]])`

Ngoài ra, kiểu dữ liệu **set** và **tuple** cũng khá thường được sử dụng để biểu diễn các dữ liệu có cấu trúc phức tạp.

Ví dụ về **set**: `s = {1,1,-2,3,1,4,6}`

Ví dụ về **tuple**: `t = (1,2)`

Điểm khác biệt chính giữa array và set:

+ Các phần tử trong **array** có thứ tự, và có thể trùng nhau.

+ Các phần tử trong **set** không có thứ tự, và không trùng.

Ta có thể tận dụng đặc điểm của list và set để **loại bỏ phần tử trùng nhau**. Ví dụ:

```
a = np.array([1, 2, 3, 1, 1, 2, 4, 5, 5])
b = list(set(a))
```

Kết quả sẽ là: 1,2,3,4,5.

Mặt khác, tuple được dùng để hoán vị giá trị của 2 biến với nhau. Cụ thể:

```
a = 2
b = 3
(a,b) = (b,a)
```

Kết quả sẽ là: `a = 3 và b = 2`.

2. Môi trường python và các thư viện.

Có 2 dạng môi trường chính để làm việc với python:

- Dạng 1: File code thuần (có đuôi .py).
- Dạng 2: File code kết hợp văn bản trình bày (có tài liệu gọi là nhúng code vào văn bản).

Các IDE thường dùng để code python gồm: PyCharm, VS Code, VS Studio, Google Colab, và Jupyter Notebook (2 IDE này thuộc dạng 2).

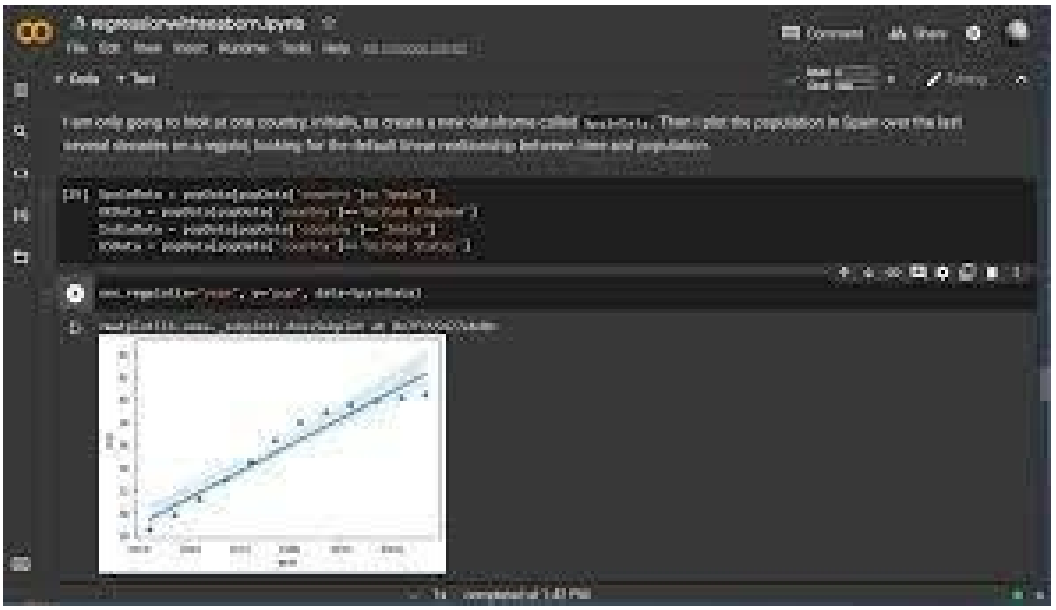

Giao diện chính của Google Colab

Các thư viện thường dùng trong máy học gồm:

- **Numpy**: thư viện xử lý ma trận và vector.
- **sklearn**: thư viện thực hiện các mô hình máy học cơ bản, và các độ đo khác nhau.
- **Matplotlib**: thư viện vẽ đồ thị.
- **Pandas**: thư viện thao tác với dataframe. Hỗ trợ thao tác đọc và xử lý dữ liệu.
- **tensorflow**: thư viện hỗ trợ lập trình xử lý ma trận và vector phục vụ cho xây dựng mạng neural.

Để cài đặt thư viện trong Python, ta dùng lệnh: `pip install <tên thư viện>`.

2. Xây dựng mô hình hồi quy tuyến tính cơ bản.

Khởi tạo dữ liệu: khởi tạo 100 điểm dữ liệu gồm X và y. y = 4+3*X + e.

Gợi ý: sử dụng hàm `np.random.rand(100, 1)`. Hàm này sẽ tạo ra 1 vector với 100 phần tử ngẫu nhiên.

Code mẫu:

```
X = 2 * np.random.rand(100, 1)
y = 4 + 3 * X + np.random.randn(100, 1)
```

Thêm giá trị bias_term vào dữ liệu X ban đầu. Mặc định bias_term là 1.

Sử dụng thư viện `np.c_[v1,v2]` để nối 2 vector v1 và v2 lại với nhau. X ban đầu có 100 điểm dữ liệu, do đó vector bias_term sẽ là 1 vector có 100 phần tử có giá trị 1. Để tạo ra 1 vector 100 phần tử có giá trị là 1, ta dùng lệnh `np.ones((100, 1)`.

Code mẫu:

```
X_b = np.c_[np.ones((100, 1)), X]
```

Câu 1: Hãy vẽ biểu đồ cho dữ liệu (X,y) vừa tạo ở trên.

Gợi ý: Sử dụng hàm `plot` với 3 tham số: X, y và "b.". Nhớ khai báo thư viện matplotlib để vẽ đồ thị.

Kết quả dự kiến:

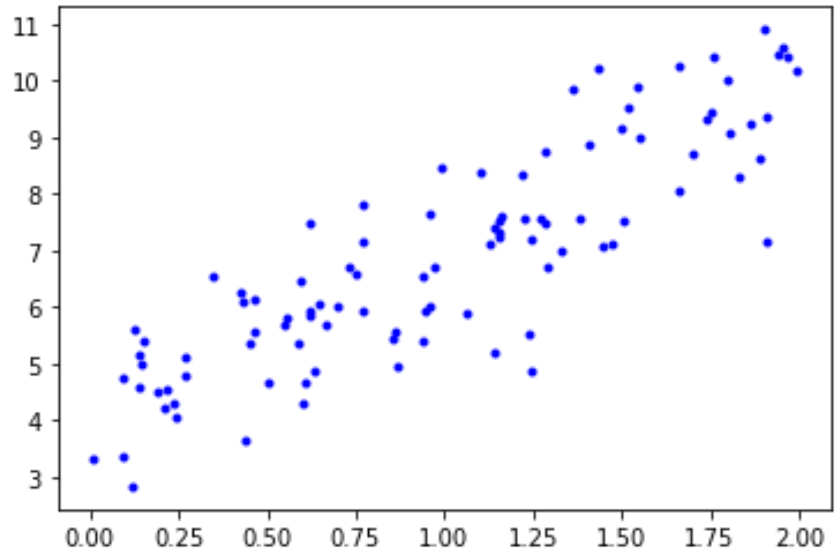

Câu 2: Hãy cho biết chiều (shape) của X_b và y.

Gợi ý: Dùng lệnh `X_b.shape`

Câu 3: Hãy viết code python tìm ra tham số tối ưu cho mô hình hồi quy tuyến tính. Tìm tham số tối ưu cho mô hình bằng phương trình sau: $\hat{\theta} = \left(X^T X\right)^{-1} X^T y$ (Xem lại slide bài giảng về hồi quy để hiểu cách tại sao tìm ra được phương trình này). Kết quả lưu vào biến theta_best.

Gợi ý: **Sử dụng X_b thay cho X** (X_b là dữ liệu X ban đầu đã thêm bias_term vào).

- X^T là ma trận chuyển vị. Sử dụng lệnh `X.T` trong Python (điều kiện là X đã ép kiểu về *numpy_array*).
- $X^T X$ là phép tích vô hướng (dot product) giữa 2 vector. Sử dụng lệnh `np.dot()` trong thư viện numpy.
- $\left(X^T X\right)^{-1}$ là phép tính nghịch đảo của ma trận. Sử dụng lệnh `np.linalg.inv(A)` để tính nghịch đảo của ma trận A. Thay A = $X^T X$.

Tạo ra dữ liệu mới X_new bằng đoạn lệnh sau (dùng để kiểm tra):

```
X_new = np.array([[0], [2]])
X_new_b = np.c_[np.ones((2, 1)), X_new]
```

Câu 4: Hãy dùng tham số tối ưu của hồi quy tuyến tính vừa tìm được ở Câu 3, dự đoán kết quả cho **X_new_b**. Giá trị dự đoán lưu vào biến **y_pred**.

Gợi ý: $\hat{y} = X\hat{\theta}$. Sử dụng tích vô hướng (dot product) để tìm ra $\hat{y}$ (chính là kết quả dự đoán). Tính tích vô hướng bằng lệnh `np.dot()`.

Câu 5: Hãy vẽ biểu đồ thể hiện kết quả dự đoán trên dữ liệu.

Gợi ý: Vẽ 2 biểu đồ bằng lệnh `plot` trong thư viện matplotlib:

- *Biểu đồ 1*: vẽ biểu đồ cho dữ liệu huấn luyện ban đầu X,y. Tham số gồm: X, y, "b." (chấm màu xanh dương - blue)
- *Biểu đồ 2*: vẽ biểu đồ cho mô hình hồi quy tuyến tính dưới dạng đường thẳng. Tham số gồm: X_new_b, y_pred, "r-" (dấu gạch màu đỏ - red).

3. Bài tập

Các bạn sử dụng Jupyter notebook hoặc Google Colab để thực hiện các câu hỏi.

Bài 1: Thực hiện lại các câu hỏi (Câu 1 đến Câu 5) trong mục 2 để xây dựng lại mô hình hồi quy tuyến tính.

Bài 2: Thực hiện xây dựng mô hình hồi quy đa thức (Polynomial Regression) cho dữ liệu đa thức như sau:

Dữ liệu huấn luyện:

```
m=100
X = 6 * np.random.rand(m, 1) - 3
y = 0.5 * X**2 + X + 2 + np.random.randn(m, 1)
```

Dữ liệu dự đoán:

```
X_new = np.linspace(-3, 3, 100).reshape(100, 1)
```

Gợi ý: sử dụng lớp ***PolynomialFeatures*** trong sklearn để chuyển giá trị trong X và X_new về thành dạng bậc 2 (dữ liệu phi tuyến) theo đoạn code mẫu như sau:

```
from sklearn.preprocessing import PolynomialFeatures


poly_features = PolynomialFeatures(degree=2,
include_bias=False)
X_poly = poly_features.fit_transform(X)
```

Dữ liệu huấn luyện sẽ thành: **(X_poly, y).**

Các bước còn lại các bạn thực hiện giống như Bài 1

Bài 3: Hãy xây dựng mô hình hồi quy Ridge. Thực hiện tương tự như Bài 1.

Gợi ý: Tham số tối ưu cho mô hình Ridge Regression được tính như sau:

$$\theta = (X^T X + \alpha I)^{-1} X^T y$$

Chọn tham số α là 0.02. Để tạo ma trận đơn vị, ta sử dụng lệnh: `np.identity(M)`, với M là kích thước của ma trận đơn vị I.

Bài 4*: Các bạn hãy so sánh giữa tham số tối ưu tìm được bằng tay và bằng thư viện sklearn trong Bài 1 và Bài 3. So sánh kết quả thu được giữa thực hiện bằng tay và bằng thư viện.

Gợi ý: Các bạn tham khảo thư viện như sau:

Hồi quy tuyến tính:

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html

Hồi quy Ridge:

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html

Các bạn làm trực tiếp trên file jupyter notebook, đặt tên là:

MSSV_BaiThucHanh1.ipynb (hoặc .jpynb)

Các bạn nộp trên course theo thời gian quy định nhé.